Análisis inmobiliario urbano

Reporte del proyecto y soportes de la segunda entrega

Ivette Yvonne Campos Bravo · Jecika Nataly León Linares
Juan Sebastián Victoria Sánchez · Guillermo Prieto Peralta

Contexto del problema

El proyecto apoya la selección preliminar de municipios donde profundizar estudios de inversión inmobiliaria. El problema consiste en comparar actividad transaccional y montos históricos bajo criterios comunes, sin confundir un mayor valor registrado con rentabilidad o valorización de inmuebles equivalentes. El Registro de Transacciones Inmobiliarias del IGAC describe un universo de 30.905.678 registros de 1.105 municipios entre 2015 y 2023. Esa escala justifica organizar y filtrar la información para apoyar decisiones territoriales; no todos esos registros corresponden a compraventas urbanas elegibles.

La comparación monetaria requiere controlar la inflación: el DANE reportó una variación anual del IPC de 13,12 % en diciembre de 2022 y de 9,28 % en diciembre de 2023. Comparar montos nominales de distintos años puede atribuir al mercado diferencias que provienen del cambio general de precios. La utilidad del proyecto es orientar dónde ampliar la investigación con información física, oferta, arriendos y costos, antes de comprometer recursos en un estudio de inversión.

Pregunta de negocio

¿Cómo apoyar a los inversionistas en la priorización de municipios para profundizar estudios de inversión inmobiliaria urbana, mediante la comparación de su actividad transaccional histórica y sus valores registrados?

Alcance y datos

Se analizan 273.734 registros de compraventas urbanas con valor positivo y sin múltiples valores, correspondientes a Armenia, Manizales, Pereira, Dosquebradas, Santa Rosa de Cabal y Calarcá. Se usan datos del IGAC y una serie anual del IPC para expresar los montos en COP constantes de diciembre de 2023. Cada fila representa un registro de operación; no se supone que sea un inmueble único. El alcance continúa siendo un piloto regional, no una priorización nacional.

Cambios frente a la primera entrega

Se amplió la cobertura de tres a seis municipios y se pasó del corte monetario de 214.036 a 273.734 registros; por tanto, las cifras de ambas entregas no se comparan como una misma población. Se incorporó inflación, se exploraron tres atributos registrales adicionales y se evaluaron cuatro alternativas supervisadas frente a una mediana municipal. La maqueta evolucionó a un tablero funcional en Streamlit. El cuarto modelo mejora a los Random Forest en MAE, pero la mediana sigue siendo mejor en la prueba de 2023.

Búsqueda de información complementaria y nuevas variables

En respuesta a la retroalimentación recibida, el equipo ha trabajado en dos frentes: ampliar la cobertura territorial y buscar información que permita caracterizar mejor los inmuebles. La incorporación de tres municipios adicionales fortalece la comparación regional; paralelamente, se están revisando fuentes oficiales para identificar variables que aporten información adicional al municipio, el año y los atributos registrales actualmente utilizados.

La búsqueda se ha orientado hacia características como área construida, número de habitaciones y baños, cantidad de pisos, uso del inmueble y año de construcción. Estos atributos podrían ayudar a explicar diferencias entre los valores registrados que los predictores actuales no permiten representar.

Las gestiones reportadas por el equipo comprenden:

Fuente o gestión	Propósito de la revisión
Geovisor del Observatorio Inmobiliario del DANE	Explorar información sobre la dinámica inmobiliaria y posibles fuentes complementarias.
Colombia en Mapas	Identificar información geográfica que pueda aportar contexto territorial al análisis.
Registros R1 y R2 de Pereira publicados en Datos Abiertos Colombia	Revisar la disponibilidad de atributos catastrales y posibles identificadores para relacionarlos con las transacciones.
Servicio SINIC del IGAC y herramientas oficiales de Catastro de Armenia	Examinar información predial y sus posibilidades de integración con la base actual.
Contacto con el Área Metropolitana del Centro Occidente	Solicitar orientación y acceso a información catastral que permita ampliar las características disponibles.

Hallazgos y limitaciones de integración

La ausencia del valor de compraventa en una fuente catastral no impide utilizarla como información complementaria, siempre que pueda enlazarse correctamente con los registros que ya contienen la variable objetivo. La principal condición pendiente es verificar esa correspondencia. Una coincidencia únicamente por municipio no permite asignar características de un inmueble a una operación específica.

Por esta razón, **las nuevas variables identificadas todavía no se han incorporado a los modelos evaluados**. Su inclusión dependerá de comprobar la disponibilidad de identificadores, la cobertura temporal, la calidad de los datos y su disponibilidad al momento de realizar una estimación.

Estas gestiones muestran que la ampliación de información continúa en desarrollo. El siguiente paso consiste en revisar la información solicitada a la entidad, validar los datos y, si resulta confiable, comparar el desempeño del modelo enriquecido frente a las alternativas actuales y la mediana municipal, utilizando un esquema temporal que preserve una evaluación independiente.

Datos y preparación

La base de modelado contiene once columnas y no presenta nulos. Se comprobó que todas las filas cumplen los filtros URBANO, COMPRAVENTA, valor > 0 y tiene_mas_de_un_valor = 0. La fuente completa y el subconjunto analizado tienen unidades y coberturas distintas; la base recibida ya está filtrada y no permite reconstruir su porcentaje de exclusión frente al universo original.

Variables y uso en el análisis

Campo	Interpretación y tratamiento
municipio / year_radica	Ubicación municipal y año de radicación. Predictores de los modelos base y filtros del tablero.
num_anotacion	Consecutivo generado por el registro de la transacción; predictor registral adicional.
count_a / count_de	Conteos de receptores y otorgantes de los efectos jurídicos del acto, respectivamente. En compraventas se asocian con adquirentes y transmitentes [1].
valor_real_2023	Objetivo continuo en COP constantes de diciembre de 2023. Se usa sin recorte de extremos.
valor / ipc_diciembre	Monto nominal e índice anual para construir el objetivo. No se usan como predictores.
Zona, naturaleza e indicador de múltiples valores	Campos constantes tras los filtros. Se usan como controles, no aportan discriminación al modelo.

Ajuste por inflación

Valor real de 2023 = valor nominal × IPC de diciembre de 2023 / IPC de diciembre del año del registro. El índice de referencia del CSV es 137,72. La auditoría verificó la consistencia de esta fórmula en todas las filas. El IPC de diciembre aproxima el conjunto de operaciones de cada año; no reemplaza un ajuste mensual. El número de inmuebles no se ajusta por inflación, y el hecho de que la mediana real sea más alta no demuestra que las mismas propiedades hayan subido de valor.

Cobertura del subconjunto

Municipio	Registros	Cobertura
Armenia	86.708	2015–2023
Calarcá	2.565	2021–2023
Dosquebradas	42.713	2015–2023
Manizales	66.295	2015–2023
Pereira	61.181	2015–2023
Santa Rosa de Cabal	14.272	2015–2023

Fuentes de los modelos desarrollados

Fuentes	Entradas y entrenamiento
Mediana municipal	Referencia estadística de comparación: mediana del objetivo por municipio calculada solo con entrenamiento.
Random Forest base	Utiliza el municipio y el año de la operación. Combina 100 árboles de decisión, con una configuración que permite reproducir los resultados y penaliza más los errores grandes durante el entrenamiento.
Random Forest ampliado	Municipio, año, num_anotacion, count_a y count_de. Misma configuración del Random Forest base.
Random Forest logarítmico	Municipio y año. Se entrena con log(1 + valor real) y se aplica exp(predicción) − 1 para evaluar en COP.
Gradient Boosting MAE (En Evaluación)	Los cinco predictores del modelo ampliado. HistGradientBoostingRegressor con pérdida absoluta; codificación categórica del municipio y salida convertida de millones a COP.

Separación temporal y selección

Validación principal: entrenamiento 2015–2021 (211.695 registros) y validación 2022 (33.648). La mediana de referencia y los codificadores se ajustan únicamente con entrenamiento. No se mezclan años mediante una partición aleatoria. La métrica principal es MAE, promedio de la diferencia absoluta entre el valor real y la predicción; menor es mejor. Se reportan RMSE, mediana del error absoluto y R^2 como diagnóstico adicional.

Para Gradient Boosting se probaron seis configuraciones. Se eligió el menor MAE de 2022: 15 hojas, mínimo 100 registros por hoja y 200 iteraciones. Un corte adicional de 2021, con entrenamiento hasta 2020, en el momento este se encuentra en revisión por parte del equipo.

Prueba final: después de congelar la configuración se reentrenaron los métodos con 2015–2022 (245.343 registros) y se evaluaron sobre 2023 (28.391). No se usó 2023 para seleccionar parámetros, filtros ni reglas municipales.

Resultados de validación y prueba

La tabla principal corresponde a la reproducción sobre las mismas filas y el mismo objetivo en COP constantes de 2023. El porcentaje expresa 100 × (MAE del método / MAE de la mediana − 1). Un signo negativo indica mejora. Las comparaciones deben hacerse dentro de cada año: la población y la distribución de montos cambian entre 2022 y 2023.

Método	MAE 2022 COP	Vs mediana	MAE 2023 COP	Vs mediana
Mediana municipal	123.569.926	+0,00 %	102.315.763	+0,00 %
RF base	132.447.816	+7,18 %	119.777.921	+17,07 %
RF ampliado	132.944.055	+7,59 %	141.651.430	+38,45 %
RF logarítmico	126.185.917	+2,12 %	109.010.651	+6,54 %
Gradient Boosting MAE	122.494.923	-0,87 %	103.250.347	+0,91 %

En MLflow, el RF ampliado registra $132.951.077 para 2022; la reproducción complementaria obtuvo $132.944.055, una diferencia de $7.022.

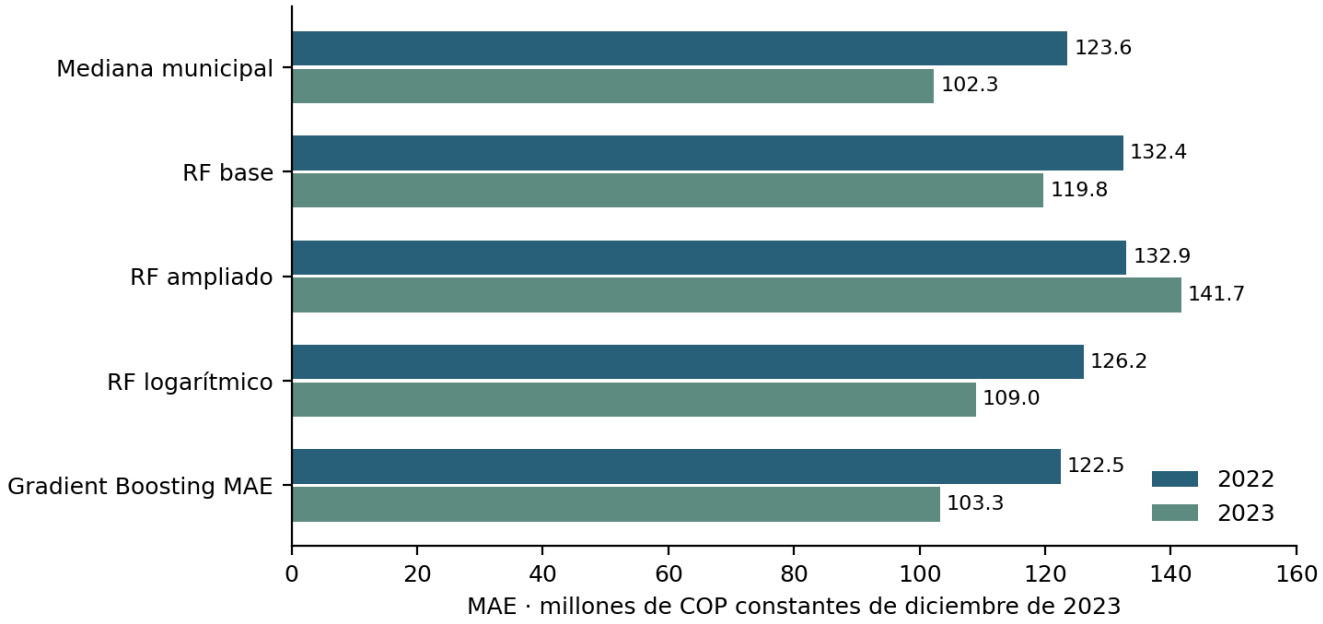


Figura 1. MAE sobre el mismo corte anual. Fuente: resultados reproducidos del conjunto aportado.

Gradient Boosting reduce el MAE frente al Random Forest logarítmico un 2,93 % en validación y un 5,28 % en prueba. Frente a la mediana, mejora 0,87 % en 2022, pero empeora 0,91 % en 2023.

Qué explican las métricas

Método	Mediana error 2022 M COP	Mediana error 2023 M COP	R^2 2022	R^2 2023
Mediana municipal	66,29	60,46	-0,0007	-0,0022
RF logarítmico	57,67	58,72	-0,0015	-0,0062
Gradient Boosting MAE -En evalaución	64,95	61,59	-0,0008	-0,0035

La mejora se concentra en MAE, no en todas las métricas: el RF logarítmico mantiene una menor mediana del error absoluto. Gradient Boosting presenta R^2 negativo y RMSE de $2.258,13 millones en 2022 y $943,13 millones en 2023. Los montos desde el percentil 99 concentran cerca del 31,8 % y 19,2 % de su error absoluto, respectivamente. Esos registros permanecen en la evaluación y no se consideran errores de datos sin revisión.

Aporte de las variables y decisión

Con la misma configuración de Gradient Boosting, usar solo municipio y año produce MAE de $123.046.464 en 2022; añadir los atributos registrales lo reduce a $122.494.923. El aporte existe, pero es pequeño y no resuelve la falta de área, uso, ubicación específica y estado físico. El RF ampliado tampoco mejora al RF base. Agregar columnas no garantiza aumentar la información útil.

Se mantiene la mediana municipal como referencia principal y el RF logarítmico como estimador experimental que ya está integrado al tablero. Gradient Boosting se documenta como cuarto candidato en evaluación y pruebas es su estado en el momento.

Fuentes del tablero desarrollado.

Se desarrolló un tablero interactivo en Streamlit que permite explorar y comparar la actividad inmobiliaria urbana de seis municipios del Eje Cafetero: Armenia, Manizales, Pereira, Dosquebradas, Santa Rosa de Cabal y Calarcá. La herramienta utiliza 273.734 registros de compraventas correspondientes al periodo 2015–2023, con valores monetarios expresados en pesos constantes de diciembre de 2023.

El tablero adapta la maqueta presentada en la primera entrega e integra indicadores, gráficos, tablas y estimaciones experimentales. Su propósito es apoyar la selección preliminar de municipios donde profundizar estudios de inversión inmobiliaria, considerando tanto el comportamiento histórico de las operaciones como las limitaciones de los datos.

La navegación se organiza en ocho vistas:

Vista	Funcionalidad
Inicio	Presenta el número de operaciones, la mediana del valor registrado y la cantidad de municipios seleccionados, junto con gráficos de actividad transaccional.
Por municipio	Permite consultar la evolución anual de las operaciones, su variación frente al año anterior y la distribución de los valores registrados.
Comparación	Facilita la comparación entre municipios mediante gráficos de actividad, evolución de las medianas y tablas con valores en millones de COP de 2023.
Cobertura	Muestra los valores faltantes, la disponibilidad de registros por municipio y año, y el cumplimiento de los filtros definidos para el análisis.
Alertas	Identifica valores extremos mediante una regla exploratoria basada en el rango intercuartílico —RIQ— de cada municipio y año. Permite descargar los registros señalados.
Estimaciones	Presenta las predicciones del Random Forest logarítmico junto con la mediana histórica de entrenamiento y permite consultar y descargar sus métricas de evaluación.

Mi estudio	Permite documentar la justificación de la selección de un municipio y descargar un resumen preliminar del estudio.
Proyecto	Describe la fuente de los datos, el objetivo del producto y sus principales limitaciones.

Los filtros de municipio y periodo permiten ajustar la exploración histórica. La vista Cobertura presenta información del archivo completo, mientras que Estimaciones conserva una separación fija de entrenamiento y validación para mantener la comparabilidad de sus resultados.



Figura 2. Vista de inicio del tablero de análisis inmobiliario urbano. Se observan los filtros de municipio y periodo, los indicadores generales y la comparación de la actividad transaccional. Para la selección completa se muestran 273.734 operaciones, seis municipios y una mediana registrada de $106,14 millones de COP constantes de 2023.

Funcionamiento de las estimaciones

La vista Estimaciones utiliza un Random Forest con transformación logarítmica del valor objetivo. El modelo se entrena con registros de 2015–2021 y se evalúa con datos de 2022. Permite consultar estimaciones para 2022 y 2023 utilizando el municipio y el año de la operación, sin reentrenarse cuando cambian los filtros históricos.

Para facilitar la interpretación, cada predicción se presenta junto con la mediana municipal calculada únicamente con los datos de entrenamiento. Por ejemplo, para Armenia en 2022, la ejecución local mostró una estimación de $74,06 millones y una mediana de referencia de $84,26 millones. También se presentan el error absoluto medio —MAE— global y por municipio.

Las estimaciones se mantienen como un componente experimental: no constituyen avalúos comerciales ni permiten determinar la rentabilidad de una inversión. Además, consultar 2023 en esta vista no equivale a la prueba final con reentrenamiento hasta 2022 descrita en la evaluación de modelos.

Verificación funcional y descargas

Se verificó localmente la ejecución de las ocho vistas mediante las herramientas de prueba de Streamlit, sin encontrar excepciones de aplicación. Las vistas Inicio y Comparación mostraron los indicadores correspondientes al conjunto completo. La vista Alertas identificó 15.066 registros mediante la regla de 1,5 RIQ por municipio y año; estas señales requieren revisión y no representan irregularidades confirmadas.

La herramienta permite descargar las alertas y las métricas de evaluación en formato CSV, así como el resumen del estudio preliminar en formato TXT.

Fuentes y acceso

El tablero se desarrolló con Python, Streamlit, pandas, Plotly y scikit-learn. Sus principales archivos fuente son app.py y core.py, ubicados en la carpeta Entrega_2/Tablero del repositorio. La versión revisada corresponde al commit 91d4d68.

- **Tablero:** Análisis inmobiliario urbano
- **Código fuente:** Repositorio del proyecto

Evidencias de MLflow y AWS EC2

Las capturas a continuación permiten relacionar la máquina de AWS, el usuario del entorno y la dirección usada por MLflow. Se conserva la IP visible en las evidencias, 3.80.230.117, y el puerto 8050.

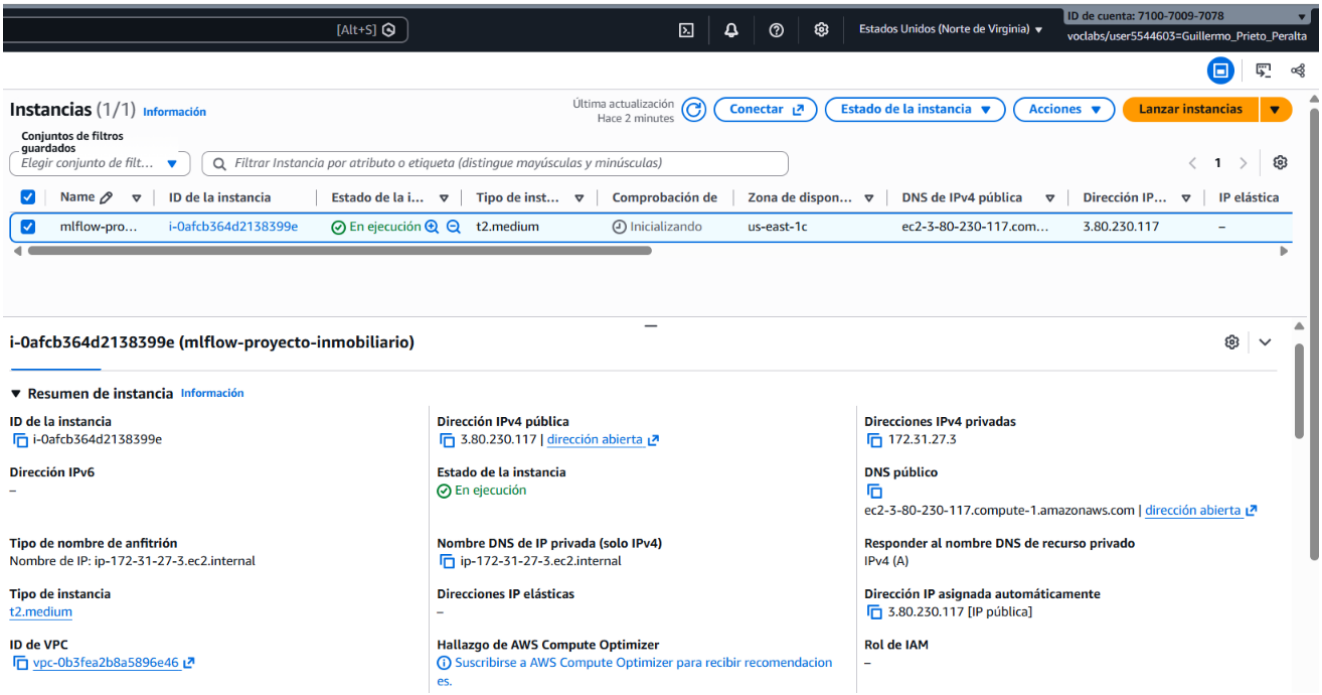


Figura 3. Consola EC2: usuario de la cuenta, instancia mlflow-proyecto-inmobiliario y dirección pública 3.80.230.117.

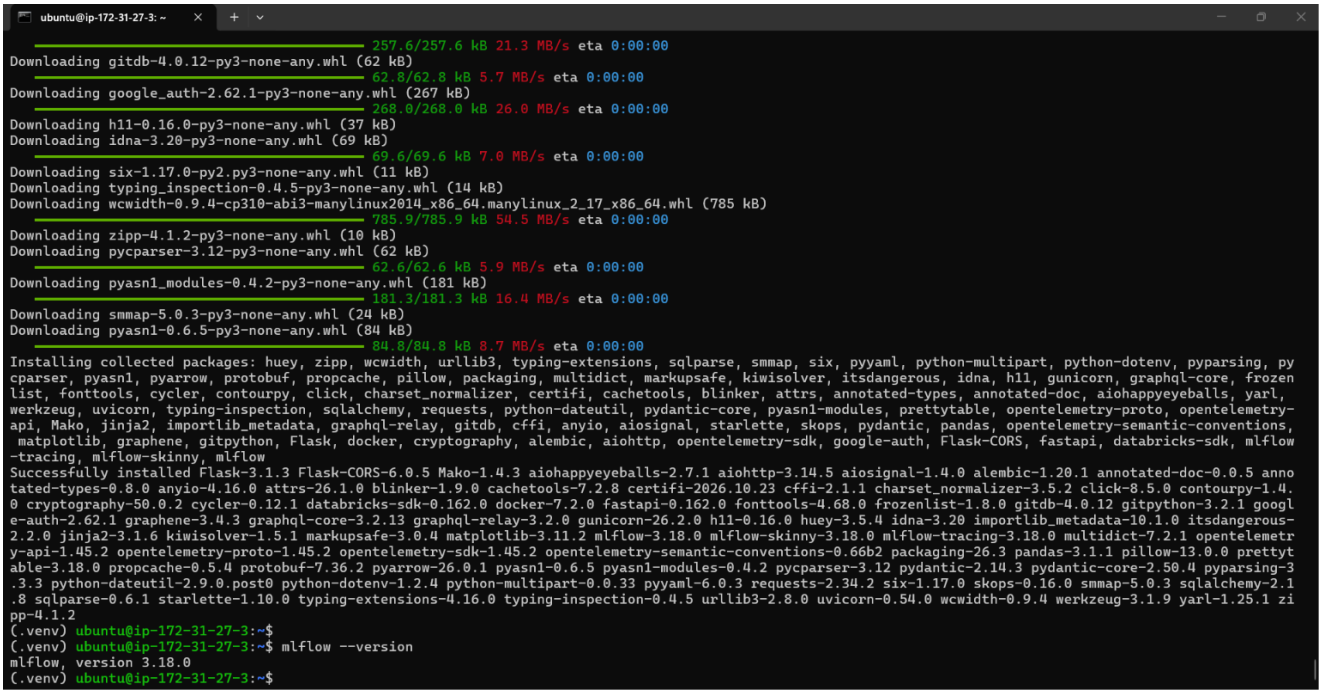


Figura 4. Instalación de MLflow 3.18.0 y usuario ubuntu en el host privado ip-172-31-27-3, coherente con la consola de EC2.

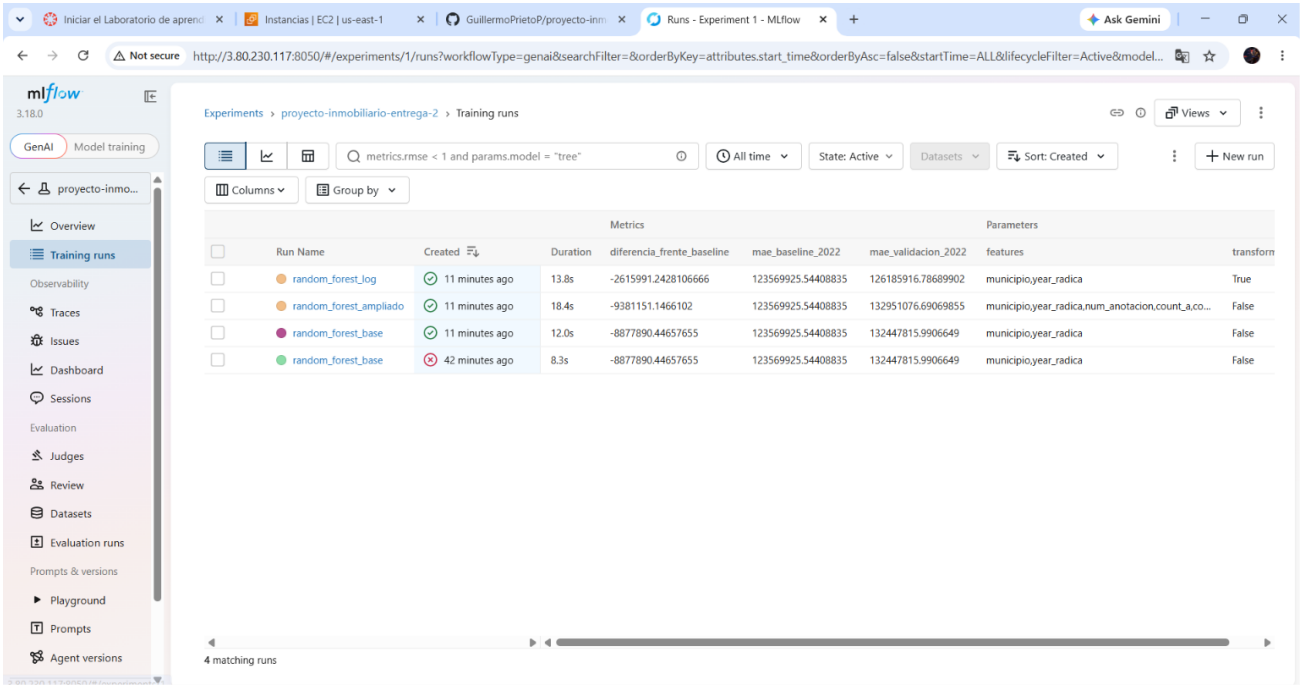


Figura 5. Experimento proyecto-inmobiliario-entrega-2 en MLflow, con la IP visible en la URL.

Los parámetros visibles incluyen entradas y transformación logarítmica; las métricas muestran MAE de 2022 y referencia.

Reporte de trabajo en equipo

El trabajo se distribuyó entre preparación y evaluación de modelos, trazabilidad de experimentos, desarrollo del tablero y documentación. El repositorio central permite verificar las contribuciones individuales; los siguientes identificadores corresponden a commits existentes, no al commit final de este informe.

Guillermo Prieto Peralta

Desarrolló los experimentos de Random Forest y su registro con MLflow en EC2, organizó los archivos de análisis y consolidó resultados y documentación. Reportó revisión local y puesta en línea del tablero. Evidencias: 1e78725, experimentos MLflow; d29bda0 y 6381329, análisis y organización; 0b09050, aporte al reporte.

Juan Sebastián Victoria Sánchez

Preparó la evaluación de 2023 para comparar predicciones por operación contra la mediana municipal, amplió la revisión de variables y reportó gestiones para obtener datos adicionales. Ajustó el formato numérico del tablero y documentó su funcionalidad. Evidencias: b2d2775, evaluación temporal; 80d04f0, formato del tablero; f6e876e, reporte de participación.

Ivette Yvonne Campos Bravo

Revisó la evaluación y los límites de los modelos, creo y adaptó la maqueta al tablero Streamlit y desarrolló sus ocho vistas, indicadores, descargas y componente experimental. Consolidó cambios mediante pull requests. Evidencias: 391d2d0, actualización del reporte; 7bc992c, fuentes del tablero; cf71897 y 6eeab5b, integración de contribuciones.

Jecika Nataly León Linares

Incorporó la propuesta alternativa de Gradient Boosting con pérdida absoluta y protocolo temporal, y participó en la consolidación del informe teniendo en cuenta la retroalimentación de los tutores. La presente versión documenta la evaluación complementaria del cuarto modelo y su comparación con los Random Forest y la mediana. Evidencia en Git: 91d4d68.

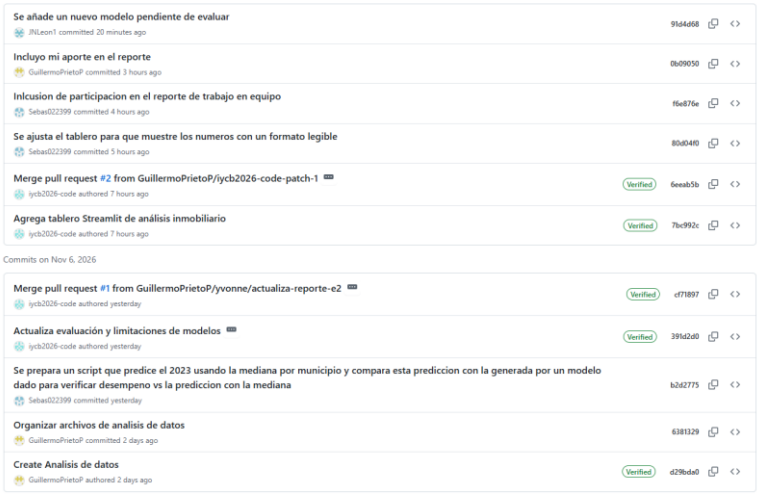


Figura 6. Evidencia Git

Repositorio y fuentes: https://github.com/GuillermoPrietoP/proyecto-inmobiliario-dsa/tree/main/Entrega_2

Entrega final documento: **2468175**

Referencias y soportes

IGAC. Registro de transacciones inmobiliarias 2015–2023 y diccionario.

DANE. IPC diciembre de 2023, comunicado del 9 de enero de 2024.

Historial Git aportado; CSV de 273.734 filas; fuentes del repositorio.